

Kratak opis HiRGC kompresije

HiRGC (*High-speed and high-ratio referential genome compression*) je visokoperformansni algoritam namijenjen **referencijskoj kompresiji genomskih podataka** (u FASTA formatu). Algoritam iskorištava činjenicu da su genomi unutar iste vrste izrazito slični (primjerice, dva ljudska genoma podudaraju se preko 99%). Umjesto zasebnog komprimiranja svake datoteke, on sprema isključivo razlike između ciljanog (*target*) genoma i postojećeg referentnog (*reference*) genoma.

Cijeli proces kompresije odvija se kroz tri ključne faze:

1. Predobrada (Pre-processing):

- **Čišćenje podataka:** Iz izvornih FASTA datoteka izdvajaju se popratne informacije, a sekvenca se pročišćava tako da ostaju isključivo osnovne baze $\Psi = \{A, C, G, T\}$. Sva mala slova automatski se pretvaraju u velika.
- **2-bitno kodiranje:** Budući da postoje samo 4 baze, svaka se baza pretvara u 2 bita, čime se cijela sekvenca transformira u niz 2-bitnih cijelih brojeva radi brže računalne obrade.

2. Pohlepno podudaranje (Greedy matching):

- Nad referentnom sekvencom gradi se indeksna hash tablica koristeći unaprijed definiranu duljinu k -mera (najčešće $K = 16$ ili $K = 32$).
- Algoritam prolazi kroz ciljanu sekvencu s lijeva na desno i traži najdulja moguća točna podudaranja (*longest prefix match*) u referentnom genomu.
- Kada pronađe podudaranje, taj se cijeli segment (baze dobivene preko podudaranja ili *bases via matches*) zamjenjuje sa samo dva broja: početnom pozicijom u referentnom genomu i duljinom podudaranja (*match records*). Dijelovi koji se ne podudaraju spremaju se kao upravo taj jedan literal (*literal records*).

3. Naknadna obrada i završna kompresija (Post-processing):

- Nakon što se generiraju zapisi o podudaranjima i literali, ti podaci prolaze kroz još jednu kompresiju.
- Na generiranu izlaznu tekstualnu datoteku primjenjuje se 7-Zip koji dodatno maksimalno sažima te strukturirane zapise razlika u konačnu **.7z** arhivu.

Glavne prednosti algoritma:

- **Iznimna brzina:** Znatno je brži od starijih srodnih algoritama zahvaljujući naprednoj i optimiziranoj pretrazi hash tablica.
- **Stabilnost i robusnost:** Rezultati i učinkovitost kompresije ne ovise drastično o samom izboru referentnog genoma.
- **Visok omjer kompresije:** Spremanjem samo minijaturnih razlika, datoteke od nekoliko stotina megabajta uspješno se sažimaju na svega nekoliko megabajta ili čak kilobajta, što dovodi do izuzetno niskih postotaka u konačnom omjeru kompresije (oko 0.1% – 1% izvorne veličine).




Figure 1: Prikaz implementacije dinamičkog skaliranja tablice

Na slici je prikazan osnovni princip rada algoritma kompresije. Postupak započinje analizom k-mera s lijeve strane, koji je uspješno lociran unutar prethodno izgrađenog indeksa (hash tablice). Nakon inicijalnog pronalaska, algoritam nastoji proširiti taj k-mer pretraživanjem svih njegovih pojavljivanja u indeksu kako bi se odredilo ono koje generira najdulje točno podudaranje (*longest prefix match*) s ciljanom sekvencom. Po završetku tog procesa, identificirano najdulje podudaranje kodira se i zapisuje isključivo preko njegove početne pozicije i ukupne duljine.

U nastavku su prikazane osnovne performanse algoritma na pojedinim primjerima:

Table 1: Sveobuhvatni rezultati kompresije po kromosomima, bakterijama i umjetnim podacima

Krom. / Podaci	Ref.	Cilj	Zapisi podud.	Doslovni zap.	Baze podud.	Izvorna vel. (B)	Stisnuta vel. (B)	Omjer (%)
1	chr1.fa	tar_chr1.fa	235,099	19,855,414	229,101,008	248,956,422	1,325,002	0.532222
2	chr2.fa	tar_chr2.fa	62,993	1,798,676	240,394,853	242,193,529	289,421	0.1195
3	chr3.fa	tar_chr3.fa	121,796	1,495,458	196,800,101	198,295,559	359,477	0.181283
4	chr4.fa	tar_chr4.fa	75,443	1,408,596	188,805,959	190,214,555	149,261	0.0784698
5	chr5.fa	tar_chr5.fa	147,261	1,120,642	180,417,617	181,538,259	352,380	0.194108
6	chr6.fa	tar_chr6.fa	82,996	1,164,039	169,641,940	170,805,979	524,865	0.307287
7	chr7.fa	tar_chr7.fa	89,341	703,104	158,642,869	159,345,973	450,678	0.28283
8	chr8.fa	tar_chr8.fa	30,974	449,096	144,689,540	145,138,636	128,720	0.0886876
9	chr9.fa	tar_chr9.fa	143,384	17,298,621	121,096,096	138,394,717	567,369	0.409964
10	chr10.fa	tar_chr10.fa	150,064	1,717,129	132,080,293	133,797,422	835,745	0.624635
Bakterije								
<i>E. coli</i>	<i>ecoli-K-12</i>	ecoli_res.fa	45,379	1,602,979	3,991,626	5,594,605	731,039	13.0669
<i>B. japonicum</i>	<i>Bradyrhizobium-japonicum</i>	B_japonicum.fa	30,260	9,363,683	500,195	9,863,878	3,241,334	32.8606
Umjetni podaci								
podaci 1	ref_1_1000.fa	tgt_1_1000.fa	11	10	990	1,000	317	31.7
podaci 2	ref_2_10000.fa	tgt_2_10000.fa	64	156	9,844	10,000	699	6.99
podaci 3	ref_3_100000.fa	tgt_3_100000.fa	654	1,345	98,655	100,000	3,812	3.812
podaci 4	ref_4_1000000.fa	tgt_4_1000000.fa	6,683	13,817	986,183	1,000,000	34,269	3.4269
podaci 5	ref_5_10000000.fa	tgt_5_10000000.fa	67,047	138,254	9,861,746	10,000,000	331,426	3.31426

Kratak opis HiRGC dekompresije

Dekompresija u **HiRGC** algoritmu sastoji se od rekonstrukcije izvorne .fa datoteke iz komprimirane arhive i u potpunosti je simetrična u odnosu na kompresiju. Budući da se radi o algoritmu bez gubitaka (*lossless compression*), ovim je procesom osigurana potpuno precizna rekonstrukcija izvornog ciljanog genoma iz referentnog. Cijeli proces dekompresije, koji je vizualno prikazan na slici 2, odvija se kroz četiri ključne faze:




Figure 2: Prikaz procesa HiRGC dekompresije i rekonstrukcije ciljanog genoma

1. Raspakiravanje arhive (Unzipping):

- Na samom početku provjerava se format datoteke. Pomoću vanjskog alata (7-Zip) vrši se ekstrakcija ulazne .txt.7z arhive kako bi se dobila osnovna tekstualna datoteka (.txt) koja sadrži sažete informacije i zapise.

2. Učitavanje metapodataka i referentnog genoma:

- Iz ekstrahirane tekstualne datoteke iščitavaju se sigurnosna riječ (HIRG), izvorni redak zaglavlja te ključni metapodaci potrebni za rekonstrukciju.
- Metapodatci uključuju naziv i putanju referentne datoteke, izvornu duljinu ciljanog genoma, veličinu k-mera, te točne pozicije i duljine blokova s nepoznatim nukleotidima (tzv. *N blokovi*) i blokova s malim slovima (*lower-case blocks*).
- Nakon što su svi metapodatci učitani, u memoriju se učitava cjelokupan referentni genom koji služi kao osnova za popunjavanje ciljane sekvence.

3. Rekonstrukcija sekvence (Decoding):

- Algoritam sekvencijalno čita pojedinačne oznake (tagove) iz datoteke.
- Kada naiđe na podudaranje (**oznaka 'M'** za *match*), iščitava poziciju u referentnom genomu te duljinu podudaranja, a zatim jednostavno kopira taj cijeli segment izravno iz referentnog genoma i dodaje ga u rekonstruiranu sekvencu.
- Kada naiđe na doslovni zapis (**oznaka 'L'** za *literal*), algoritam preuzima upravo taj jedan specifični znak (A, C, G ili T) iz datoteke i nadovezuje ga na sekvencu.

4. Vraćanje popratnih informacija i formatiranje (Post-processing):

- Nakon što je osnovna sekvenca od baza $\Psi = \{A, C, G, T\}$ u cijelosti izgrađena, algoritam vrši naknadnu obradu koristeći ranije učitane metapodatke.
- Na točno definirane pozicije i u točnim duljinama vraćaju se znakovi 'N', a određene baze ponovno se pretvaraju u mala slova, čime se vraća potpuno izvorno stanje znakova.
- Za kraj, rekonstruirani se genom ispisuje u izlaznu FASTA datoteku uz vraćanje originalnog FASTA zaglavlja i standardno razlamanje teksta (najčešće po 50 znakova po retku).

References

- [1] Yuansheng Liu, Hui Peng, Limsoon Wong, Jinyan Li. *High-speed and high-ratio referential genome compression*. Bioinformatics, Oxford University Press.
- [2] yuansliu/HiRGC: *High-speed and high-ratio referential genome compression*. GitHub repozitorij, dostupno na: <https://github.com/yuansliu/HiRGC>.