

Kratak opis HiRGC kompresije

HiRGC (High-speed and high-ratio referential genome compression) je visokoperformansni algoritam namijenjen referencijskoj kompresiji genomskih podataka (u FASTA formatu). Algoritam iskorištava činjenicu da su genomi unutar iste vrste izrazito slični (primjerice, dva ljudska genoma podudaraju se preko 99%). Umjesto zasebnog komprimiranja svake datoteke, on sprema isključivo razlike između ciljanog (*target*) genoma i postojećeg referentnog (*reference*) genoma.

Cijeli proces kompresije odvija se kroz tri ključne faze:

1. Predobrada (Pre-processing)

- Čišćenje podataka Iz izvornih FASTA datoteka izdvajaju se popratne informacije, a sekvenca se pročišćava tako da ostaju isključivo osnovne baze $\Psi = \{A, C, G, T\}$. Sva mala slova automatski se pretvaraju u velika.
- 2-bitno kodiranje Budući da postoje samo 4 baze, svaka se baza pretvara u 2 bita, čime se cijela sekvenca transformira u niz 2-bitnih cijelih brojeva radi brže računalne obrade.

2. Pohlepno podudaranje (Greedy matching)

- Nad referentnom sekvencom gradi se indeksna hash tablica koristeći unaprijed definiranu duljinu k -mera (najčešće $K = 16$ ili $K = 32$).
- Algoritam prolazi kroz ciljanu sekvencu s lijeva na desno i traži najdulja moguća točna podudaranja (longest prefix match) u referentnom genomu.
- Kada pronađe podudaranje, taj se cijeli segment (baze dobivene preko podudaranja ili bases via matches) zamjenjuje sa samo dva broja: početnom pozicijom u referentnom genomu i duljinom podudaranja (match records). Dijelovi koji se ne podudaraju spremaju se kao upravo taj jedan literal (literal records).

3. Naknadna obrada i završna kompresija (Post-processing)

- Nakon što se generiraju zapisi o podudaranjima i literali, ti podaci prolaze kroz još jednu kompresiju.
- Na generiranu izlaznu tekstualnu datoteku primjenjuje se 7-Zip koji dodatno maksimalno sažima te strukturirane zapise razlika u konačnu .7z arhivu.

Glavne prednosti algoritma:

- Iznimna brzina Znatno je brži od starijih srodnih algoritama zahvaljujući naprednoj i optimiziranoj pretrazi hash tablica.
- Stabilnost i robusnost Rezultati i učinkovitost kompresije ne ovise drastično o samom izboru referentnog genoma.
- Visok omjer kompresije Spremanjem samo minijaturnih razlika, datoteke od nekoliko stotina megabajta uspješno se sažimaju na svega nekoliko megabajta ili čak kilobajta, što dovodi do izuzetno niskih postotaka u konačnom omjeru kompresije (oko 0.1% – 1% izvorne veličine).




Figure 1: Prikaz implementacije dinamičkog skaliranja tablice

Na slici je prikazan osnovni princip rada algoritma kompresije. Postupak započinje analizom k-mera s lijeve strane, koji je uspješno lociran unutar prethodno izgrađenog indeksa (hash tablice). Nakon inicijalnog pronalaska, algoritam nastoji proširiti taj k-mer pretraživanjem svih njegovih pojavljivanja u indeksu kako bi se odredilo ono koje generira najdulje točno podudaranje (longest prefix match) s ciljanom sekvencom. Po završetku tog procesa, identificirano najdulje podudaranje kodira se i zapisuje isključivo preko njegove početne pozicije i ukupne duljine.

U nastavku su prikazane osnovne performanse algoritma na pojedinim primjerima:

Table 1: Rezultati kompresije po kromosomima, bakterijama i umjetnim podacima

Krom. / Podaci	Ref.	Cilj	Zapisi podud.	Doslovni zap.	Baze podud.	Izvorna vel. (B)	Stisnuta vel. (B)	Omjer (%)
1	chr1.fa	tar_chr1.fa	235,099	19,855,414	229,101,008	248,956,422	1,325,002	0.532222
2	chr2.fa	tar_chr2.fa	62,993	1,798,676	240,394,853	242,193,529	289,421	0.1195
3	chr3.fa	tar_chr3.fa	121,796	1,495,458	196,800,101	198,295,559	359,477	0.181283
4	chr4.fa	tar_chr4.fa	75,443	1,408,596	188,805,959	190,214,555	149,261	0.0784698
5	chr5.fa	tar_chr5.fa	147,261	1,120,642	180,417,617	181,538,259	352,380	0.194108
6	chr6.fa	tar_chr6.fa	82,996	1,164,039	169,641,940	170,805,979	524,865	0.307287
7	chr7.fa	tar_chr7.fa	89,341	703,104	158,642,869	159,345,973	450,678	0.28283
8	chr8.fa	tar_chr8.fa	30,974	449,096	144,689,540	145,138,636	128,720	0.0886876
9	chr9.fa	tar_chr9.fa	143,384	17,298,621	121,096,096	138,394,717	567,369	0.409964
10	chr10.fa	tar_chr10.fa	150,064	1,717,129	132,080,293	133,797,422	835,745	0.624635
Bakterije								
<i>E. coli</i>	<i>ecoli-K-12</i>	ecoli_res.fa	45,379	1,602,979	3,991,626	5,594,605	731,039	13.0669
<i>B. japonicum</i>	<i>Bradyrhizobium-japonicum</i>	B_japonicum.fa	30,260	9,363,683	500,195	9,863,878	3,241,334	32.8606
Umjetni podaci								
podaci 1	ref_1_1000.fa	tgt_1_1000.fa	11	10	990	1,000	317	31.7
podaci 2	ref_2_10000.fa	tgt_2_10000.fa	64	156	9,844	10,000	699	6.99
podaci 3	ref_3_100000.fa	tgt_3_100000.fa	654	1,345	98,655	100,000	3,812	3.812
podaci 4	ref_4_1000000.fa	tgt_4_1000000.fa	6,683	13,817	986,183	1,000,000	34,269	3.4269
podaci 5	ref_5_10000000.fa	tgt_5_10000000.fa	67,047	138,254	9,861,746	10,000,000	331,426	3.31426

Kratak opis HiRGC dekompresije

Dekompresija u HiRGC algoritmu sastoji se od rekonstrukcije izvorne .fa datoteke iz komprimirane arhive i u potpunosti je simetrična u odnosu na kompresiju. Budući da se radi o algoritmu bez gubitaka (*lossless compression*), ovim je procesom osigurana potpuno precizna rekonstrukcija izvornog ciljanog genoma iz referentnog. Cijeli proces dekompresije, koji je vizualno prikazan na slici 2, odvija se kroz četiri ključne faze:




Figure 2: Prikaz procesa HiRGC dekompresije i rekonstrukcije ciljanog genoma

1. Raspakiravanje arhive (Unzipping)

- Na samom početku provjerava se format datoteke. Pomoću vanjskog alata (7-Zip) vrši se ekstrakcija ulazne .txt.7z arhive kako bi se dobila osnovna tekstualna datoteka (.txt) koja sadrži sažete informacije i zapise.

2. Učitavanje metapodataka i referentnog genoma

- Iz ekstrahirane tekstualne datoteke iščitavaju se sigurnosna riječ (HIRG), izvorni redak zaglavlja te ključni metapodaci potrebni za rekonstrukciju.
- Metapodatci uključuju naziv i putanju referentne datoteke, izvornu duljinu ciljanog genoma, veličinu k-mera, te točne pozicije i duljine blokova s nepoznatim nukleotidima (tzv. *N blokovi*) i blokova s malim slovima (*lower-case blocks*).
- Nakon što su svi metapodatci učitani, u memoriju se učitava cjelokupan referentni genom koji služi kao osnova za popunjavanje ciljane sekvence.

3. Rekonstrukcija sekvence (Decoding)

- Algoritam sekvencijalno čita pojedinačne oznake (tagove) iz datoteke.
- Kada naiđe na podudaranje (oznaka 'M' za match), iščitava poziciju u referentnom genomu te duljinu podudaranja, a zatim jednostavno kopira taj cijeli segment izravno iz referentnog genoma i dodaje ga u rekonstruiranu sekvencu.
- Kada naiđe na doslovni zapis (oznaka 'L' za literal), algoritam preuzima upravo taj jedan specifični znak (A, C, G ili T) iz datoteke i nadovezuje ga na sekvencu.

4. Vraćanje popratnih informacija i formatiranje (Post-processing)

- Nakon što je osnovna sekvenca od baza $\Psi = \{A, C, G, T\}$ u cijelosti izgrađena, algoritam vrši naknadnu obradu koristeći ranije učitane metapodatke.
- Na točno definirane pozicije i u točnim duljinama vraćaju se znakovi 'N', a određene baze ponovno se pretvaraju u mala slova, čime se vraća potpuno izvorno stanje znakova.
- Za kraj, rekonstruirani se genom ispisuje u izlaznu FASTA datoteku uz vraćanje originalnog FASTA zaglavlja i standardno razlamanje teksta (najčešće po 50 znakova po retku).

Literatura

Yuansheng Liu, Hui Peng, Limsoon Wong, Jinyan Li. *High-speed and high-ratio referential genome compression*. Bioinformatics, Oxford University Press.

yuansliu/HiRGC: *High-speed and high-ratio referential genome compression*. GitHub repozitorij, dostupno na: <https://github.com/yuansliu/HiRGC>.